


SUPORTE AO DIAGNÓSTICO · SAÚDE DA MULHER

Detecção de câncer de *mama* com Machine Learning.



EQUIPE

Claudio · Laís · Pedro · Renan

DATASET

Breast Cancer Wisconsin (Diagnostic)

DURAÇÃO

~10 min · vídeo de demonstração

CONTEXTO CLÍNICO

Uma rede de saúde da mulher precisa **acelerar a triagem** e apoiar o diagnóstico com inteligência artificial.

1^a

causa de morte por câncer entre mulheres no mundo. Detecção precoce muda o prognóstico.

FN

Falso negativo é o erro mais grave: paciente com tumor maligno volta para casa sem tratamento.

SISTEMA DE APOIO À DECISÃO

Classificador binário **Maligno / Benigno** treinado em features morfológicas extraídas de citologia FNA.

- 01 Pipeline reproduzível em **Jupyter + Docker**, com base pública e código aberto.
- 02 Cinco modelos comparados sob a **mesma divisão de treino/teste** e mesmas métricas.
- 03 Métrica priorizada: **Recall** da classe maligna — minimizar falsos negativos.
- 04 Explicabilidade com **feature importance + SHAP** para apoiar o médico, não substituí-lo.

COMO O NOTEBOOK ESTÁ ORGANIZADO

Sete seções, do dado bruto à decisão explicável.



BREAST CANCER WISCONSIN (DIAGNOSTIC)

Pequena, limpa e bem rotulada.

Amostras	569
Features numéricas	30
Target	diagnosis (M / B)
Distribuição	357 B · 212 M
Valores nulos	0
Duplicados	0
Origem	UCI · Kaggle

Cada amostra descreve o núcleo celular em três agregados — `_mean`, `_se` e `_worst` — para 10 medidas morfológicas.

10 medidas × 3 agregações

- radius
- perimeter
- area
- concavity
- concave points
- texture
- smoothness
- compactness
- symmetry
- fractal dimension

Em destaque, as cinco famílias mais correlacionadas com o diagnóstico — todas ligadas a **tamanho** e **irregularidade** do núcleo, marcadores clássicos de malignidade.


LIMPEZA MÍNIMA, DECISÕES JUSTIFICADAS

Decisões de preparação dos dados.

- 01 **Encoding do target.** `diagnosis` mapeada de $\{M, B\}$ para $\{1, 0\}$.
- 02 **Colunas removidas.** `id` e `Unnamed: 32` (coluna fantasma 100% nula).
- 03 **Tentativa de redução.** Remover blocos `_mean/_worst` piorou o resultado — código ficou comentado.
- 04 **Integridade.** 0 nulos, 0 duplicados.
- 05 **Split 80/20** com `random_state=42`.

TOP 10 FEATURES × DIAGNOSIS

Tamanho e irregularidade do núcleo são os **sinais mais fortes**.



Forte correlação linear → motiva escolha de famílias **lineares** de classificador (SVC linear, regressão logística). Também explica os warnings de overflow no PCA: features altamente correlacionadas geram instabilidade numérica.

O CUSTO DO ERRO

Em câncer,
errar para menos
é o pior erro.

Otimizamos pelo **Recall da classe maligna**: porcentagem de tumores realmente malignos que o modelo consegue identificar. Para forçar isso, usamos `class_weight={0:1, 1:5}` — o modelo paga 5x mais por um falso negativo do que por um falso positivo.

- RECALL ↑
- PRECISION
- F1
- ACCURACY

	PRED. BENIGNO	PRED. MALIGNO
REAL BENIGNO	VN ACEITÁVEL	FP EXAME EXTRA
REAL MALIGNO	FN PERIGOSO	VP TRATAMENTO

Matriz de confusão · peso 1 : 5

CINCO MODELOS · 80/20 · MESMO SPLIT

Resultados no conjunto de teste.

MODELO	ACURÁCIA	RECALL (M)	PRECISÃO (M)	F1-SCORE
SVC Linear C=2 · weight 1:5	0,9386	0,9767	0,8750	0,9231
Linear Regression threshold ≥ 0,5	0,9561	0,9070	0,9750	0,9398
Decision Tree max_depth=5	0,9474	0,9302	0,9302	0,9302
▶ Logistic Regression weight 1:5	0,9737	0,9767	0,9545	0,9655
KNN k=5	0,9561	0,8837	1,0000	0,9383

SVC Linear e Logistic Regression empatam em recall (0,9767) — Logistic Regression vence em todas as outras métricas.

LOGISTIC REGRESSION · CLASS_WEIGHT 1 : 5

97,67% dos
tumores malignos
identificados.

RECALL

0,9767

ACURÁCIA

0,9737

PRECISÃO

0,9545

F1-SCORE


0,9655

O QUE O MODELO ESTÁ REALMENTE "OLHANDO"

Feature importance + SHAP.


SVC LINEAR · PERMUTATION IMPORTANCE

Queda média na acurácia



LOGISTIC REGRESSION · |COEF|

Importância por coeficiente



SVC e Logistic Regression — calculados de formas diferentes — concordam nas mesmas regiões: medidas de **tamanho** (radius, perimeter, area) e de **irregularidade do contorno** (concave points, concavity). SHAP confirma essas mesmas features no topo, ranqueadas pelo impacto médio na predição da Regressão Logística.

O QUE APRENDEMOS

Um modelo simples, bem ajustado e **explicável** já entrega valor clínico real.

- **Pesar o erro** (1 : 5) foi mais impactante do que trocar de algoritmo.
- **Alta correlação** entre features causa instabilidade numérica em PCA e SHAP do SVC.
- **Reduzir colunas** à mão piorou o resultado — o modelo aproveita a redundância.
- Próximos passos: padronização (StandardScaler), validação cruzada, ensemble.

*O modelo é um
copiloto de triagem —
nunca a palavra final.*

MÉDICO MANTÉM A DECISÃO CLÍNICA